


Modyfikacja środowiska i implementacja algorytmu Dyna-Q

Artur Szabelski, Dominik Zieliński

8 maja 2026

Modyfikacja 1 - Klif

- ▶ Rozmiar planszy: 6×12
- ▶ Wpadnięcie do klifu skutkuje dużą karą oraz przeniesieniem gracza na start




Rysunek: Wyznaczona polityka na podstawie VI

Sarsa vs Q-Learning, slip = 0.0

Algorytm Sarsa wybiera dłuższą i bezpieczniejszą drogę.




Rysunek: Polityka Q-Learning




Rysunek: Polityka Sarsa

Sarsa vs Q-Learning, slip = 0.2



Rysunek: Polityka Q-Learning



Rysunek: Polityka Sarsa

Dyna-Q: Zestawienie dla różnych konfiguracji epizodów i iteracji planowania, przy stałym iloczynie tych parametrów

Epizody	Plan.	Czas [s]	Avg Ret	Std Ret	Succ %	Steps
3000	10	14.9	4.34	3.83	100%	21.66
1000	30	14.9	4.34	4.16	100%	21.66
600	50	15.1	4.84	3.68	100%	21.16
300	100	19.4	3.24	3.30	100%	22.76
200	150	20.7	-11.62	37.13	100%	23.76

Parametry stałe: $\alpha = 0.1$, $\gamma = 0.99$, $\epsilon \in [1.0, 0.01]$ (decay 0.99).

Modyfikacja 2 - Wiele Celów

- ▶ Rozmiar planszy: 5x7
- ▶ Cele mogą mieć różne nagrody
- ▶ Odwiedzenie 1 celu skutkuje zakończeniem gry


S						
			15 G			
6 G						40 G

Rysunek: Plansza w stanie początkowym


Porównanie wartości współczynnika dyskontowego γ

γ	Succ %	Avg Ret	Std Ret	Steps
0.99	100%	28.74	2.11	12.26
0.95	96%	25.94	10.44	12.42
0.90	100%	8.34	2.17	7.66
0.70	100%	4.56	3.53	5.32

Heatmapy dla γ 0.7 oraz 0.95



Rysunek: Heatmapa dla $\gamma = 0.95$



Rysunek: Heatmapa dla $\gamma = 0.7$

Modyfikacja 3 - Ruszający się cel

- ▶ Rozmiar planszy 5x7
- ▶ Cel może się poruszać do sąsiednich kratek
- ▶ Cel ma prawdopodobieństwo 0.8 wykonania ruchu

Greedy Policy						
S	↓	↓	↓	↓	↓	←
→	→	↓	↓	↓	←	←
→	→	→	↓	←	←	←
→	→	→	T	←	←	←
→	→	↑	↑	↑	←	←


Rysunek: Polityka wyznaczona z VI dla stanu początkowego

Porównanie Dyna-Q z innymi algorytmami


Algorytm	Succ %	Avg Ret	Std Ret	Steps
Dyna-Q	96%	-7.16	13.05	17.72
Q-Learning	100%	-1.00	5.23	12.00
SARSA	100%	-1.26	6.02	12.26
Value Iteration	100%	-0.02	3.90	11.02

W przeciwieństwie do innych środowiskami gdzie stanów było znacznie mniej, Dyna-Q sobie nie radzi. W obecnym środowisku jest 1225 stanów, przez co algorytm nie ma czasu na stworzenie wiarygodnego modelu.

20 epizodów - Q-Learning vs VI




Rysunek: Q-Learning




Rysunek: VI

20 epizodów - SARSA vs VI




Rysunek: SARSA




Rysunek: VI

20 epizodów - DynaQ vs VI



Rysunek: DynaQ



Rysunek: VI